SVEUČILIŠTE U ZAGREBU
FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

Kolegij: Seminar

SEMINAR

Primjena umjetne inteligencije pri upravljanju projektima

Autor: Roko Šabić

Zagreb, travanj 2026.

SADRŽAJ

1. Uvod

2. Umjetna inteligencija u upravljanju projektima

    2.1. Definicija i temeljni pojmovi

    2.2. Trokut upravljanja projektima i uloga AI-a

    2.3. Metodologije upravljanja projektima

3. AI u ključnim tehnikama upravljanja projektima

    3.1. Izrada strukture rada (WBS)

    3.2. Korisničke priče i upravljanje zahtjevima

    3.3. Vremensko raspoređivanje i Gantt dijagram

    3.4. Praćenje napretka: Burndown i Velocity

    3.5. Status izvještavanje (Progress Report)

    3.6. Traceability Matrix

4. Pregled AI alata u praksi

    4.1. ChatGPT – generativni AI asistent

    4.2. GitHub Copilot u softverskom razvoju

    4.3. Specijalizirani PM alati

    4.4. Usporedba AI PM alata

5. Automatizacija rutinskih zadataka

    5.1. Konkretni primjeri automatizacije

    5.2. Prediktivna analitika i upravljanje rizicima

6. Etička i sigurnosna ograničenja

    6.1. Privatnost i povjerljivost podataka

    6.2. Problem halucinacija u planiranju projekata

7. Zaključak

Literatura

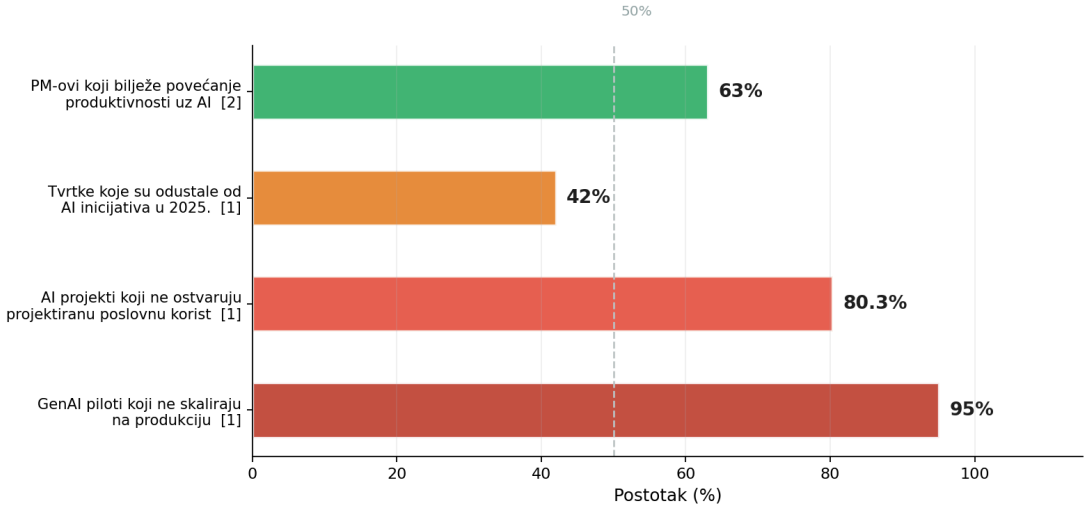
Sažetak

1. UVOD

Upravljanje projektima važan je dio rada svake organizacije koja razvija softver ili pruža usluge. Ono obuhvaća planiranje, raspodjelu zadataka, praćenje napretka i izvještavanje – discipline koje tradicionalno zauzimaju velik dio radnog vremena projektnih menadžera. Posljednjih godina umjetna inteligencija (engl. artificial intelligence, AI) ulazi u ovo područje kao alat koji obećava ubrzanje i automatizaciju mnogih od tih zadataka.

Statistike, međutim, pokazuju zabrinjavajuće podatke. Prema pregledu statistika koji je 2025. objavio Pertama Partners, čak 80,3% projekata koji uvode AI u svoje poslovne procese ne donosi očekivanu poslovnu korist, a 33,8% njih biva napušteno prije puštanja u rad [1]. Važno je naglasiti razliku između dvije vrste projekata: ovaj rad ne bavi se projektima razvoja umjetne inteligencije, već projektima koji primjenjuju postojeće AI alate za poboljšanje upravljanja projektima u IT sektoru.

Istovremeno, 63% projektnih menadžera bilježi veću produktivnost nakon uvođenja AI alata, a zaposlenici koji koriste AI za administrativne zadatke uštede u prosjeku jedan sat dnevno [2]. Slika 1 sažima ključne statistike koje motiviraju pažljivu analizu ove teme.



Slika 1. Ključne statistike primjene AI-a u upravljanju projektima (Izvor: [1], [2])

Ti suprotni podaci postavljaju glavno pitanje ovoga rada: kako organizacije mogu iskoristiti prednosti AI-a u upravljanju projektima, a pritom izbjeći pogreške koje vode do neuspjeha? Odgovor leži u poznavanju konkretnih tehnika upravljanja projektima, alata koji ih podupiru i njihovih ograničenja.

Rad je strukturiran kako slijedi. Poglavlje 2 uvodi temeljne pojmove umjetne inteligencije i upravljanja projektima te objašnjava model Trokuta ograničenja. Poglavlje 3, koje čini središnji dio rada, detaljno obrađuje konkretne tehnike upravljanja projektima – izradu strukture rada (WBS), pisanje korisničkih priča, vremensko raspoređivanje pomoću

Gantt dijagrama, praćenje napretka kroz Burndown i Velocity, status izvještavanje te Traceability Matrix – i pokazuje kako AI olakšava svaku od tih aktivnosti. Poglavlje 4 daje pregled konkretnih AI alata (ChatGPT, GitHub Copilot, Asana, Monday.com, ClickUp) s primjerima upotrebe. Poglavlje 5 fokusira se na automatizaciju rutinskih zadataka i prediktivnu analitiku. Poglavlje 6 obrađuje etička i sigurnosna ograničenja, a poglavlje 7 donosi zaključak i pogled na budućnost uloge projektnog menadžera.

2. UMJETNA INTELIGENCIJA U UPRAVLJANJU PROJEKTIMA

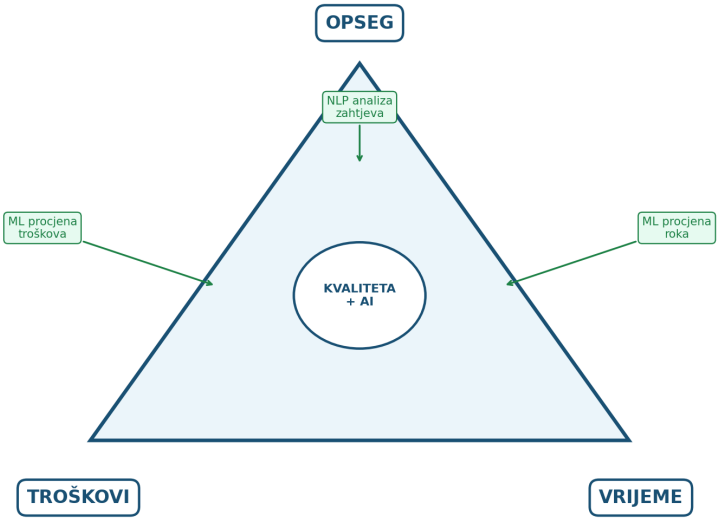
2.1. Definicija i temeljni pojmovi

Umjetna inteligencija naziv je za računalne tehnike i algoritme koji strojevima omogućavaju obavljanje zadataka koji obično zahtijevaju ljudski um – razumijevanje jezika, prepoznavanje uzoraka i donošenje odluka [3]. Ključne tehnologije koje se koriste u upravljanju projektima su:

- **Strojno učenje (engl. machine learning, ML):** algoritmi koji uče iz podataka starijih projekata i predviđaju buduće troškove, rokove ili rizike.
- **Obrada prirodnog jezika (engl. natural language processing, NLP):** razumijevanje i stvaranje teksta – osnova alata poput ChatGPT-a za analizu zahtjeva i dokumentaciju.
- **Generativna AI:** modeli koji stvaraju novi sadržaj (tekst, kod, planove) prema zadanom opisu.
- **Prediktivna analitika:** statističko modeliranje za predviđanje rizika i kašnjenja projekata.

2.2. Trokut upravljanja projektima i uloga AI-a

Klasični model Trokuta ograničenja (Project Management Triangle) opisuje tri povezane dimenzije projekta: opseg (Scope), vrijeme (Time) i troškove (Cost) [4]. Svaka promjena jedne dimenzije uvijek utječe na barem jednu od preostale dvije. AI pomaže pri svim trima: NLP ubrzava analizu zahtjeva (opseg), ML modeli točnije procjenjuju rokove, a algoritmi raspoređivanja resursa smanjuju troškove, kako je prikazano na Slici 2.



Slika 2. Trokut upravljanja projektima s AI integracijom (vlastita obrada autora)

Tablica 1. Utjecaj AI-a na dimenzije Trokuta ograničenja

Dimenzija	Tradicionalni pristup	AI-podržani pristup
Opseg	Ručna analiza zahtjeva	NLP parsira zahtjeve iz e-mailova i tiketa
Vrijeme	Iskustvene procjene trajanja	ML predviđa rok na temelju sličnih projekata
Troškovi	Proračuni u Excel tablicama	AI optimizira alokaciju resursa u realnom vremenu

2.3. Metodologije upravljanja projektima

Tehnike upravljanja projektima primjenjuju se unutar šireg metodološkog okvira. U IT industriji prevladavaju dva osnovna pristupa: kaskadni (Waterfall) i okretni (Agile), s nizom hibridnih varijanti između njih [4], [9].

- **Waterfall:** linearni pristup gdje se faze odvijaju jedna za drugom – analiza zahtjeva, dizajn, razvoj, testiranje i isporuka. Pogodan je za projekte stabilnih zahtjeva i jasnih ciljeva [4].
- **Agile / Scrum:** iterativni pristup u kojem se rad dijeli na kratke sprintove (obično 1 – 4 tjedna). Tim isporučuje funkcionalni inkrement na kraju svakog sprinta i kontinuirano prilagođava plan [9].
- **Kanban:** vizualni pristup s pločom u kolonama (To Do, In Progress, Done) i ograničenjem broja zadataka u tijeku (WIP limit) [11].
- **Hibridni pristupi (Wagile, ScrumBan):** kombinacije koje koriste predvidljivost Waterfalla i fleksibilnost Agilea.

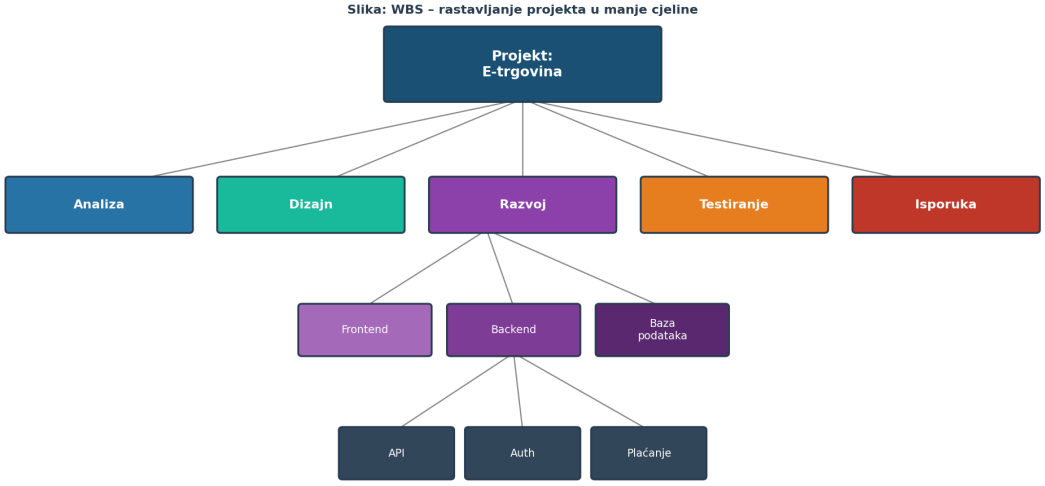
AI alati nisu vezani uz jednu metodologiju – isti ChatGPT prompt može pomoći pisati zahtjeve za Waterfall projekt ili korisničke priče za Scrum sprint. Specijalizirani alati poput Asane i Jire, međutim, posebno su optimizirani za Agile timove, gdje se AI najlakše integrira u sprint planiranje i retrospektive.

3. AI U KLJUČNIM TEHNIKAMA UPRAVLJANJA PROJEKTIMA

Ovo poglavlje obrađuje konkretne tehnike upravljanja projektima i pokazuje kako AI alati ubrzavaju ili pojednostavljuju svaku od njih. Za svaku tehniku najprije se opisuje tradicionalni postupak, a zatim način na koji AI mijenja taj postupak.

3.1. Izrada strukture rada (WBS)

Work Breakdown Structure (WBS) hijerarhijski je prikaz svih zadataka koje treba obaviti da bi se projekt završio. WBS rastavlja projekt u sve manje cjeline – od glavnih faza prema pojedinačnim isporukama – tako da se svaki list stabla može samostalno procijeniti, dodijeliti i pratiti [4]. Slika 3 prikazuje primjer WBS-a za projekt razvoja platforme za e-trgovinu.



Slika 3. Primjer WBS-a za projekt razvoja platforme za e-trgovinu (vlastita obrada)

Tradicionalno, projektni menadžer ručno izrađuje WBS na workshopovima s timom, što za projekt srednje veličine traje pola dana do dva dana. AI alati ubrzavaju ovaj proces – ChatGPT iz kratkog opisa projekta generira prvi nacrt WBS-a u nekoliko sekundi:

Primjer prompta: „Generiraj WBS za razvoj mobilne aplikacije za narudžbu hrane. Tim ima 4 člana, rok je 3 mjeseca. Izlistaj glavne faze i podzadatke."

Skraćeni izvadak iz rezultata koji ChatGPT vrati (prikazane su prve dvije od pet glavnih faza; ostale slijede isti obrazac):

- **1. Analiza i planiranje:** 1.1 prikupljanje zahtjeva, 1.2 funkcionalna specifikacija, 1.3 procjena resursa i rokova

- **2. Dizajn:** 2.1 UX žičani okviri, 2.2 UI dizajn, 2.3 model baze podataka, 2.4 definicija REST API-ja
- **3. Razvoj:** 3.1 autentikacija korisnika, 3.2 katalog jela i košarica, 3.3 modul plaćanja, 3.4 push-obavijesti
- **4. Testiranje:** 4.1 jedinični testovi, 4.2 integracijski testovi, 4.3 korisničko prihvatno testiranje
- **5. Isporuka:** 5.1 objava na trgovinama aplikacija, 5.2 korisnička dokumentacija, 5.3 primopredaja i prijenos znanja

Rezultat je strukturirana lista koju projektni menadžer dalje uređuje i validira. Štedi se vrijeme jer se ne kreće s praznog papira, a projektni menadžer zadržava kontrolu nad konačnom strukturom.

3.2. Korisničke priče i upravljanje zahtjevima

Korisnička priča (engl. user story) kratak je opis funkcionalnosti iz perspektive krajnjeg korisnika. Standardni format glasi: „Kao [uloga], želim [funkcionalnost], kako bih [postigao korist]." Svaka priča ima i kriterije prihvatljivosti (acceptance criteria) koji definiraju kada se smatra završenom.

Primjer ručno napisane korisničke priče za restorane:

„Kao gladni student, želim moći rezervirati stol u obližnjem restoranu putem mobilne aplikacije, kako bih bio siguran da ću imati mjesto za večeru."

Iz iste rečenice ChatGPT, uz konkretan upit, generira povezane priče i kriterije prihvatljivosti. Upit glasi:

„Na temelju ove korisničke priče generiraj povezane korisničke priče u standardnom formatu i za glavnu priču napiši kriterije prihvatljivosti."

ChatGPT u odgovoru vraća sljedeće povezane priče:

- „Kao korisnik, želim vidjeti dostupne stolove za odabrani datum i vrijeme."
- „Kao korisnik, želim primiti potvrdu rezervacije e-mailom."
- „Kao korisnik, želim moći otkazati rezervaciju do 1 sat prije termina."
- „Kao vlasnik restorana, želim primati obavijesti o novim rezervacijama."

te kriterije prihvatljivosti za glavnu priču:

- Korisnik može odabrati datum, vrijeme i broj osoba iz padajućeg izbornika.

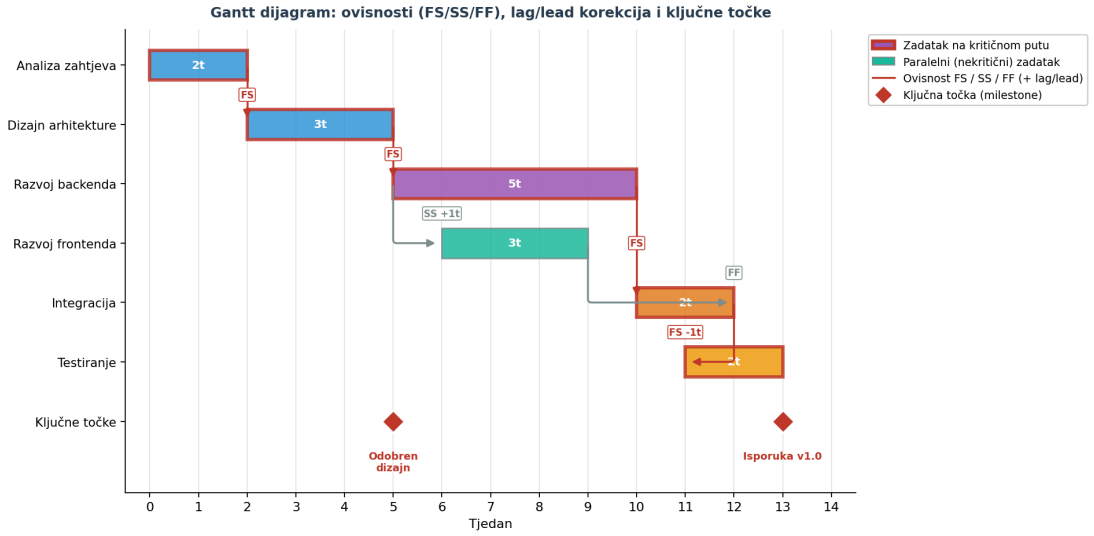
- Sustav prikazuje samo termine u kojima restoran ima slobodan stol.
- Nakon potvrde korisnik u roku od jedne minute dobiva e-mail s detaljima rezervacije.
- Rezervacija je odmah vidljiva vlasniku restorana u njegovoj nadzornoj ploči.

Time se grube poslovne ideje brzo pretvaraju u strukturirane stavke backloga spremne za procjenu i raspored u sprint.

3.3. Vremensko raspoređivanje i Gantt dijagram

Gantt dijagram horizontalni je trakasti prikaz zadataka kroz vrijeme. Svaka traka predstavlja jedan zadatak, njezina pozicija na osi vremena pokazuje kada zadatak počinje i završava, a strelice prikazuju ovisnosti između zadataka. Kritični put (Critical Path) najduži je lanac međusobno ovisnih zadataka – kašnjenje bilo kojeg zadatka na kritičnom putu odgađa cijeli projekt [4].

Ovisnosti između zadataka opisuju se jednim od četiri tipa: završetak–početak (FS), početak–početak (SS), završetak–završetak (FF) te rijetko korišteni početak–završetak (SF). Uz svaku se vezu može zadati pomak (lag) ili preklapanje (lead). Slika 4 prikazuje takav dijagram: zadaci na kritičnom putu označeni su crvenim rubom, frontend kreće tjedan nakon početka backenda (SS +1t), integracija ne smije završiti prije frontenda (FF), a testiranje se preklapa s krajem integracije (FS −1t). Ključne točke (milestones) prikazane su rombovima.



Slika 4. Gantt dijagram s ovisnostima (FS/SS/FF), lag/lead korekcijom i ključnim točkama (vlastita obrada)

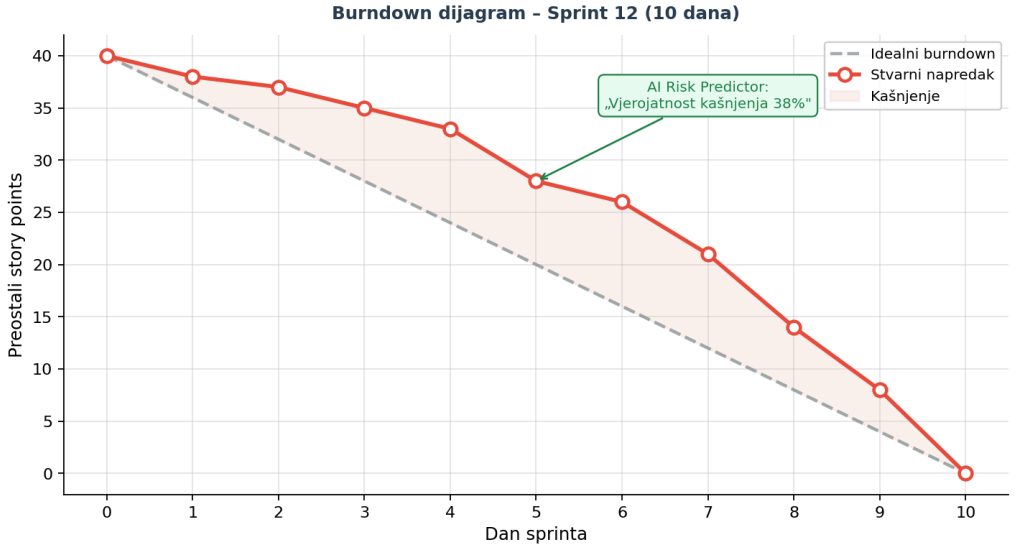
Tradicionalna izrada Gantt dijagrama uključuje ručnu procjenu trajanja svakog zadatka, najčešće metodom PERT (najpovoljnija, najvjerojatnija i najnepovoljnija procjena) ili na temelju iskustva. AI alati Asane i Monday.com-a uvode prediktivne modele koji analiziraju trajanje sličnih zadataka iz prošlih projekata i automatski predlažu realnije

procjene. ML model može, primjerice, prepoznati da zadaci tipa „integracija s vanjskim API-jem" povijesno kasne 25%, pa unaprijed predlaže dodatni vremenski buffer.

Konkretan primjer poboljšanja rasporeda: za zadatak „integracija platnog pristupnika" projektni menadžer je na temelju iskustva upisao procjenu od 5 radnih dana (stanje prije AI-a). ML model Asane analizirao je 40 sličnih integracijskih zadataka iz arhive prošlih projekata, utvrdio prosječno prekoračenje od 25% i predložio korigiranu procjenu od 6 do 7 dana te automatski pomaknuo sve zadatke koji o tom zadatku ovise (stanje poslije). Mogućnost poboljšanja je dakle dvojaka: procjene se temelje na stvarnim povijesnim podacima umjesto na optimizmu, a ovisni zadaci i konačni rok ažuriraju se automatski, bez ručnog preračunavanja rasporeda.

3.4. Praćenje napretka: Burndown i Velocity

Burndown dijagram prikazuje koliko posla ostaje u sprintu kroz vrijeme. Os Y pokazuje preostale story points (jedinice procjene veličine zadatka), a os X dane sprinta. Idealna linija je dijagonala od početnog opsega prema nuli – stvarna linija pokazuje kako tim napreduje. Velocity je prosječan broj story points koje tim završava po sprintu, što se koristi za predviđanje budućih kapaciteta [9], [10].



Slika 5. Primjer Burndown dijagrama s AI predviđanjem rizika kašnjenja (vlastita obrada)

Procjenu izrađuje alat poput Asana AI Risk Prediction, i to potpuno automatski, bez intervencije Scrum Mastera. Model se ponovno izvršava nakon svake promjene statusa zadatka – u praksi više puta dnevno – i uspoređuje procijenjenu vjerojatnost s pragom upozorenja (npr. 30%). Ulazni parametri su trenutni nagib stvarne burndown linije, broj preostalih story pointova, prosječni velocity tima, broj otvorenih blokera te ponašanje tima u prethodnim sprintovima. Kad procijenjena vjerojatnost kašnjenja prijeđe prag, sustav samostalno šalje obavijest Scrum Masteru (npr. u Slack ili Asana sandučić). Slika 5 prikazuje

takav slučaj: na polovici sprinta (5. dan) model procjenjuje 38% vjerojatnosti kašnjenja, što Scrum Masteru daje priliku za pravovremenu intervenciju – preraspodjelu zadataka ili uklanjanje blokera dok još ima vremena.

3.5. Status izvještavanje (Progress Report)

Tjedni i mjesečni status izvještaji ključno su komunikacijsko sredstvo prema naručitelju i upravi. Tipičan izvještaj sadrži: što je napravljeno u proteklom razdoblju, što slijedi, koji su rizici i koje odluke trebaju eskalaciju [4]. Tradicionalno, projektni menadžer ručno prikuplja ove podatke iz Jire, Confluencea ili Slacka – posao koji jedan PM može utrošiti i pola dana tjedno.

AI alati ovaj postupak skraćuju na minute. Ulazni podaci već postoje u samoj Asani – svaka kartica zadatka nosi status, nositelja, procjenu u story pointovima, rok i komentare, a pohranjeni su u Asaninoj bazi na njezinim poslužiteljima (alat ne poseže za vanjskim izvorima). Izvještaj pokreće projektni menadžer na zahtjev, upisivanjem upita u AI Studio (npr. „sažmi status Sprinta 23"), ili ga AI Studio generira automatski po rasporedu (npr. svakog petka u 16:00). Alat tada povlači podatke sa svih projektnih ploča tima i formatira ih u izvršni sažetak. Primjer izlaza:

„Sprint 23 status: završeno 18 od 25 korisničkih priča (72%), velocity 23 story points (prosjek 21), 2 blokirajuća problema – migracija baze i čekanje na pristup vanjskom API-ju. Predviđeni završetak: 2 dana kašnjenja od plana."

3.6. Traceability Matrix

Matrica praćenja zahtjeva (Requirements Traceability Matrix) tablica je koja povezuje svaki poslovni zahtjev s pripadajućim korisničkim pričama, dijelovima koda, test-slučajevima i prihvatnim kriterijima. Cilj je u svakom trenutku znati pokriva li se zahtjev kroz cijeli životni ciklus razvoja [4].

Održavanje ove matrice ručno je iznimno radno intenzivan posao. AI alati danas mogu automatski povezivati elemente: kad se u poruci commita na GitHubu spomene broj korisničke priče (npr. „US-42"), sustav povezuje promjenu koda s tom pričom i odgovarajućim test slučajem. Time se traceability matrica gradi i održava kontinuirano, bez ručnog rada projektnog menadžera.

Primjer: programer u poruku commita upiše „Fix: validacija e-maila pri rezervaciji (US-42)". Sustav iz poruke prepoznaje oznaku US-42, dohvaća pripadnu korisničku priču i test slučaj te automatski popunjava redak matrice, kako prikazuje Tablica 2.

Tablica 2. Primjer retka traceability matrice koji AI popunjava automatski

Zahtjev	Korisnička priča	Commit	Test slučaj	Status
R-07	US-42 (e-mail potvrda)	a1b3f9c	TC-42	Pokriveno

4. PREGLED AI ALATA U PRAKSI

4.1. ChatGPT – generativni AI asistent

ChatGPT, koji je razvio OpenAI, temelji se na velikom jezičnom modelu (engl. large language model, LLM) – tipa GPT-4 ili novijem – naučenom na ogromnoj količini teksta s interneta [5]. Može pisati smislen tekst koji odgovara kontekstu razgovora i sve je češći u svakodnevnom radu projektnih timova. Konkretne primjene u upravljanju projektima uključuju:

- Pisanje korisničkih priča iz opisa zahtjeva naručitelja
- Automatsko pisanje tehničke dokumentacije na temelju koda
- Sažimanje dugih e-mail niti i zapisnika sastanaka
- Prijedlozi rješenja za probleme koji blokiraju Scrum tim
- Pretvaranje poslovnih zahtjeva u tehničke specifikacije

Primjer za prvu stavku s popisa – pisanje korisničkih priča: na upit „Kao naručitelj želim mobilnu aplikaciju za rezervaciju termina kod frizera" ChatGPT u nekoliko sekundi generira pet do sedam strukturiranih korisničkih priča s pripadajućim kriterijima prihvatljivosti, što inače oduzima sat ili više vremena na workshopu.

Ostale primjene s popisa ilustrirane su drugdje u radu: pretvaranje zahtjeva u korisničke priče i specifikacije obrađeno je u poglavlju 3.2, sažimanje statusa i izvještaja u poglavljima 3.5 i 5, prijedlozi rješenja za blokere u poglavlju 5.1, a generiranje i objašnjavanje koda u poglavlju 4.2.

ChatGPT nije specijaliziran alat za upravljanje projektima, ali je dovoljno fleksibilan da se uklopi u gotovo svaki radni proces. Najčešće povezivanje odvija se kroz Zapier – uslugu koja bez programiranja spaja stotine aplikacija (Jira, Slack, Gmail, Trello). Tipična automatizacija izgleda ovako: kad u Jiri nastane novi tiket, Zapier ga pošalje ChatGPT-u s uputom „klasificiraj prioritet i predloži zaduženog člana tima", a rezultat upiše natrag u Jiru kao komentar. Alternativno, vlastiti API poziv s prilagođenom prompt logikom omogućuje dublju integraciju u interne alate tvrtke.

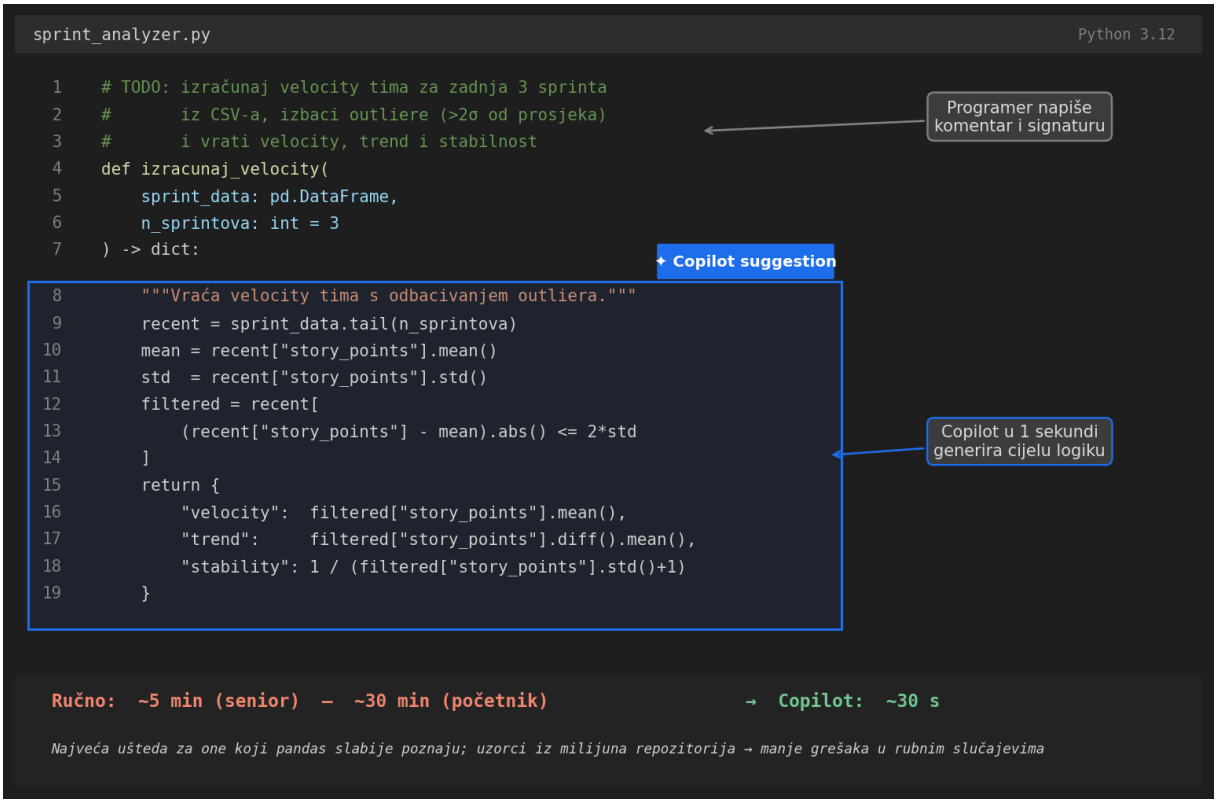
Primjer takve automatizacije: u Jiri nastane tiket „Korisnici ne mogu resetirati lozinku". Zapier ga prosljeđuje ChatGPT-u s uputom za klasifikaciju, a ChatGPT vraća: „Prioritet: visok (blokira prijavu korisnika); predloženi nositelj: tim za autentikaciju; procijenjena složenost: srednja." Zapier taj odgovor automatski upisuje natrag u Jira tiket kao komentar, bez ijednog ručnog koraka.

4.2. GitHub Copilot u softverskom razvoju

GitHub je vodeća svjetska platforma za hostanje softverskog koda – platforma na kojoj se nalazi preko 100 milijuna razvojnih projekata i koja je od 2018. godine u vlasništvu Microsofta. Bazirana je na Git sustavu za upravljanje verzijama koda i preko 90% open source projekata danas se nalazi upravo tamo.

GitHub Copilot je AI asistent koji se ugrađuje direktno u razvojno okruženje (engl. integrated development environment, IDE) poput Visual Studio Codea i predlaže programski kod na temelju komentara ili nedovršenog koda [5]. GitHub navodi da programeri koji ga koriste postaju do 55% produktivniji i 75% zadovoljniji poslom. Za upravljanje projektima to znači manji rizik kašnjenja rokova, manje grešaka u kodu i brže uvođenje novih članova tima.

Konkretan primjer iz prakse najbolje pokazuje vrijednost ovog alata. Pretpostavimo da u projektu trebamo Python funkciju koja računa velocity tima iz povijesnih sprint podataka, pritom odbacujući outliere koji bi inače iskrivili prosjek. Slika 6 prikazuje tu situaciju u Visual Studio Code editoru.



Slika 6. Put od komentara (TODO) do generiranog koda: Copilot iz opisa i tipova zaključuje strukturu i nazive podataka (vlastita obrada)

Na vrhu slike vidi se ono što programer ručno napiše: tri retka komentara i signatura funkcije s tipovima parametara. Komentar je na hrvatskom jer tim komentira na materinjem jeziku, dok je sam kod – ključne riječi, nazivi i pandas API – po uobičajenoj konvenciji na

engleskom; Copilot razumije oboje. Ulazni podatak sprint_data tipa je pandas DataFrame, učitan iz tjednog izvoza sprint podataka iz Jire (CSV datoteka sa stupcem story_points po sprintu). Generiranje se pokreće tako da programer dovrši signaturu i krene u novi redak: Copilot tada u uređivaču prikazuje prijedlog kao zasivljeni („ghost") tekst, a programer ga prihvaća pritiskom na Tab. Donji dio slike (plavo uokvireno) upravo je taj prijedlog – cijela implementacija s docstringom, filtriranjem outliera po pravilu dviju standardnih devijacija i strukturiranim povratnim rječnikom s velocityjem, trendom i mjerom stabilnosti tima.

Nazive poput story_points Copilot ne pogađa nasumično: zaključuje ih iz tipa parametra (pd.DataFrame) i namjere opisane u komentaru, oslanjajući se na uobičajene konvencije iz milijuna sličnih projekata na GitHubu. Ako se stupci u stvarnom CSV-u zovu drukčije, programer ih u prijedlogu ispravi u nekoliko sekundi – upravo se tako iz teksta TODO komentara dolazi do konkretne strukture i naziva podataka.

Da je programer ovo radio ručno, ne bi ga usporavalo tipkanje deset redaka, nego prisjećanje točnog pandas API-ja (tail, mean, std), ispravan izračun praga za outliere te rukovanje rubnim slučajevima (NaN vrijednosti, prazni sprintovi) uz kratku provjeru rezultata. Za iskusnog programera koji pandas koristi svakodnevno to je posao od oko 5 minuta; za studenta FER-a koji se s bibliotekom susreće prvi put i mora pretraživati dokumentaciju realnije je 20 do 30 minuta. Copilot u oba slučaja isti prijedlog daje za nekoliko sekundi, pa je dobitak najveći upravo kod onih koji biblioteku slabije poznaju.

Korist nije samo u brzini. Copilot u svom prijedlogu koristi obrasce iz milijuna sličnih funkcija na GitHubu, što obično znači manje grešaka u rubnim slučajevima. Programer ipak mora razumjeti i provjeriti predloženi kod. Konkretna ilustracija: prag za outliere u generiranoj funkciji postavljen je na dvije standardne devijacije. Ako je tim imao jedan sprint s neuobičajeno niskim učinkom (npr. zbog državnog praznika), to bi pravilo moglo odbaciti i taj sprint i jedan posve valjan sprint, pa bi izračunati velocity ispao previsok i nerealno optimističan. Kod je tehnički ispravan, ali poslovno pogrešno prikazuje kapacitet tima, pa takvu odluku mora potvrditi čovjek koji poznaje kontekst – ljudska provjera ostaje obavezna.

4.3. Specijalizirani PM alati

Asana, Monday.com i ClickUp samostalne su aplikacije za upravljanje projektima – svaka od njih je platforma s vlastitim web sučeljem, mobilnim aplikacijama i plaćenim pretplatama. Razlikuju se od općenitih AI modela poput ChatGPT-a po tome što AI ugrađuju direktno u svoju projektnu ploču, dashboard i tijekove rada. Prema istraživanjima iz 2025./2026. [6]:

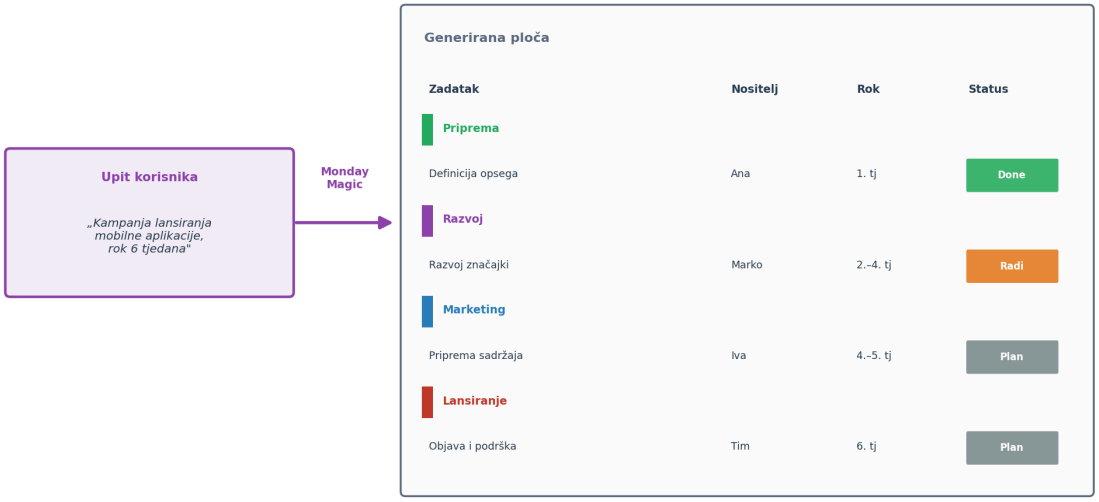
Asana Intelligence

Asana je aplikacija za upravljanje zadacima koja prikazuje projekte kao liste, ploče ili kalendare. Asana Intelligence nudi AI Studio za vizualno postavljanje automatiziranih tokova rada bez pisanja koda, predviđanje rizika projekata (AI Risk Prediction) te AI Teammates – agente koji sami obavljaju rutinske zadatke unutar same aplikacije.

Monday.com Magic i Sidekick

Monday.com je vizualna platforma s prilagodljivim pločama (engl. boards) za praćenje bilo kojeg tipa posla. Sredinom 2025. uveli su više od 12 besplatnih AI funkcija. Među njima su, primjerice: automatsko sažimanje dugih opisa zadataka, kategorizacija i izvlačenje ključnih podataka iz teksta, prijevod sadržaja, generiranje nacrta e-poruka i opisa zadataka, otkrivanje rizičnih stavki, pretvaranje slobodnog teksta u zadatke te prijedlozi automatizacija tijeka rada.

Dvije najistaknutije funkcije su Magic i Sidekick. Monday Magic kreira cijelu projektnu ploču iz jedne rečenice opisa, dok Monday Sidekick funkcionira kao asistent koji razumije detalje konkretnog projekta i tima u Monday aplikaciji. Primjerice, projektni menadžer u Magic upiše „kampanja lansiranja mobilne aplikacije, rok 6 tjedana", a alat u nekoliko sekundi izradi ploču s grupama (Priprema, Razvoj, Marketing, Lansiranje), pripadajućim zadacima, nositeljima, rokovima i statusnim stupcima (Slika 7). Sidekick zatim, poznajući sadržaj te ploče, na pitanje „koji zadaci kasne i tko ih vodi?" vraća popis zakašnjelih stavki s nositeljima i predlaže novi raspored.



Slika 7. Monday Magic iz jedne rečenice generira cijelu projektnu ploču (vlastita obrada)

ClickUp Brain

ClickUp je sve-u-jednom aplikacija koja kombinira upravljanje zadacima, dokumente, ciljeve i praćenje vremena. ClickUp Brain uvodi Super Agente kojima se zadaci dodjeljuju

kao pravom članu tima [6]. Agenti rade na temelju pravila koja korisnik definira po obrascu okidač → uvjet → akcija i podataka sa samih zadataka (statusi, polja, rokovi, nositelji). Primjerice: kad svi podzadaci nekog zadatka dobiju status „Done", agent automatski postavlja nadređeni zadatak na „Završeno" i obavještava nositelja; svakog ponedjeljka u 9:00 agent prikuplja statuse svih zadataka u sprintu i članovima tima šalje sažetak napretka s postotkom dovršenosti i popisom blokera.

4.4. Usporedba AI PM alata

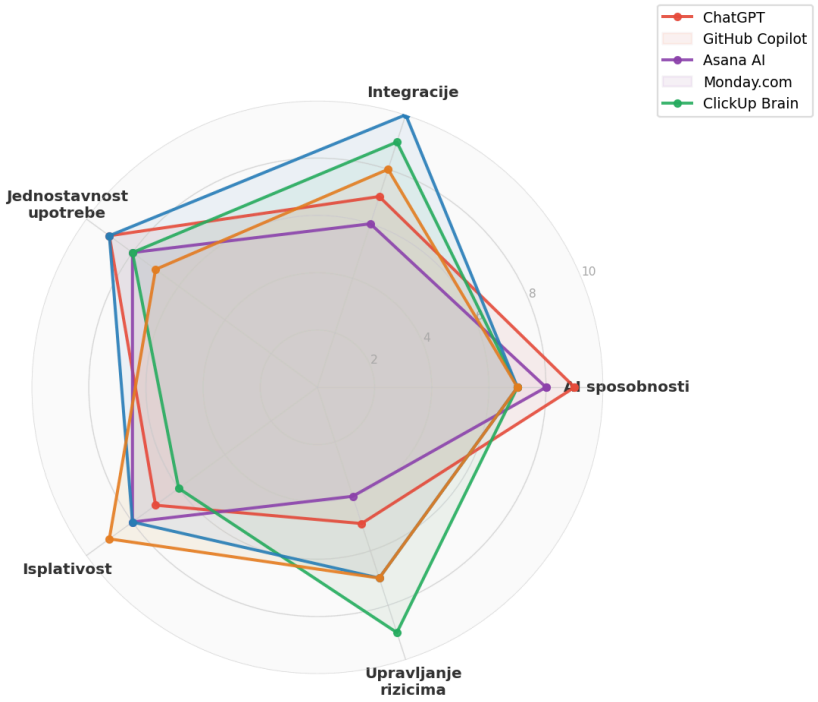
Tablica 3 prikazuje usporedbu ključnih alata prema kriterijima relevantnim za IT projektne timove, a Slika 8 vizualizira njihove relativne prednosti na pet dimenzija.

Drugi stupac tablice sažima ključnu AI funkcionalnost svakog alata: ChatGPT generira i analizira tekst te piše dokumentaciju; GitHub Copilot uz generiranje koda nudi i pregled zahtjeva za povlačenje (engl. pull request, PR) te objašnjavanje postojećeg koda; Asana AI kroz AI Studio i Risk Prediction automatizira tokove rada i predviđa rizike; Monday.com kroz Magic i Sidekick gradi ploče i odgovara na pitanja o projektu; a ClickUp Brain kroz Super Agente autonomno izvršava dodijeljene zadatke.

Tablica 3. Usporedba AI PM alata prema ključnim kriterijima (2025./2026.)

Alat	Ključna AI funkcionalnost	Cijena (USD/mj.)	Integracije	Glavna prednost
ChatGPT	Generiranje teksta, analiza, dokumentacija	od 20	API, Zapier, 1000+	Fleksibilnost
GitHub Copilot	Generiranje koda, PR pregled, objašnjenja	10 – 19	VS Code, JetBrains	Razvoj softvera
Asana AI	Risk prediction, AI Studio, AI Teammates	od 10.99	Slack, Jira, 200+	Predviđanje rizika
Monday.com	Magic, Sidekick, 12+ AI značajki	od 9	500+ integracija	Svestranost
ClickUp Brain	Super Agents, autonomno izvršavanje	od 7	GitHub, Slack, Drive	Prilagodba

Izvor: [5], [6]; vlastita obrada autora.



Slika 8. Radar-dijagram usporedbe AI PM alata po ključnim dimenzijama (vlastita obrada)

5. AUTOMATIZACIJA RUTINSKIH ZADATAKA

5.1. Konkretni primjeri automatizacije

Automatizacija je jedna od najjasnijih prednosti AI-a u upravljanju projektima. Rutinski zadaci koji oduzimaju puno vremena prenose se na AI sustave, što oslobađa vrijeme za strateški rad [7]. Za svaku od pet najvažnijih kategorija u nastavku se navodi tko što automatizira, kada i kako, te na temelju kojih podataka i pravila:

Statusni izvještaji

Tradicionalno, projektni menadžer ručno prikuplja podatke iz Jire, Confluencea i Slacka te u petak popodne piše tjedni izvještaj. Asana AI Studio svaki petak u 16:00 automatski generira izvještaj u formatu „Tim XYZ je u tjednu 23 završio 18 od planiranih 25 priča (72%), velocity 23 SP, dva otvorena blokera, predviđeno kašnjenje dva dana." Izvještaj se gradi na podacima sa svih kartica zadataka (status, story pointovi, nositelji, rokovi), uz pravilo da se zadatak broji kao dovršen kad mu je status „Done", a kao bloker kad nosi oznaku „blocked". Vrijeme uštede iznosi otprilike tri sata tjedno po projektu.

Pametne obavijesti

Slack i e-mail preplavljuju projektni tim obavijestima o svakoj sitnoj promjeni zadatka. AI filtrira ovaj šum: umjesto poruke „Korisnik X je premjestio zadatak Y", tim dobiva korisnije poruke poput „Zadatak ABC-456 vjerojatno će propustiti rok – preporučeno dodavanje druge osobe ili preraspodjela u sljedeći sprint." AI važnost procjenjuje na temelju vjerojatnosti kašnjenja zadatka (izračunate iz preostalog posla i velocityja tima) te pravila praga – obavijest se šalje samo ako ta vjerojatnost prijeđe zadanu granicu, pa tim dobiva isključivo poruke na koje treba reagirati.

Raspoređivanje resursa

Voditelj projekta tradicionalno bilježi vještine članova tima u Excelu i ručno odlučuje tko će raditi koji zadatak. ClickUp Brain analizira profile članova tima, njihovo trenutno opterećenje i tipove zadataka koje su uspješno završavali u prošlim sprintovima. Za novi backend zadatak tako preporučuje Anu (Java specijalistica, 60% kapaciteta) umjesto Marka (preopterećen, ima već tri hitna zadatka). Pravilo pritom preferira člana koji ima traženu vještinu i trenutačno opterećenje ispod 80% kapaciteta.

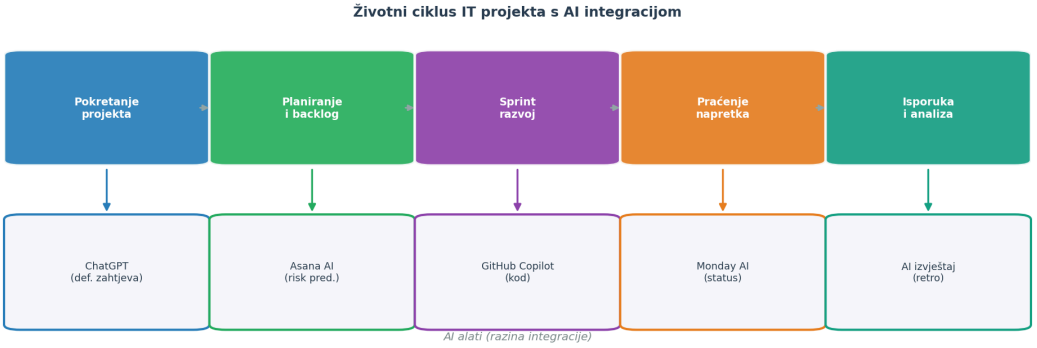
Uvođenje novih članova tima

Novi developer Borna ulazi u projekt – tradicionalno mu treba dva do tri tjedna da razumije arhitekturu, navike timskog rada i tehnologije. Asana AI Teammate prvog dana

automatski generira personalizirani plan: tri „starter" zadatka označena kao prikladna za početnike, link na arhitekturni dijagram, popis ključnih biblioteka i imena seniora kojima može postaviti pitanja. Plan se sastavlja na temelju arhitekturne dokumentacije projekta, zadataka unaprijed označenih kao „good first issue" i profila seniora zaduženih za pojedina područja. Vrijeme uvođenja skraćuje se na pet do sedam dana.

Sprint izvještaji i retrospektive

Kraj sprinta tradicionalno znači da Scrum Master ručno priprema slajdove s velocity grafom, burndownom i listom blokera. Monday.com Sidekick automatski generira prezentaciju s ključnim metrikama (velocity 23, completion ratio 92%), identificira dva ponavljajuća rizika (vanjske API ovisnosti i nedovoljno code review kapaciteta) te predlaže tri akcijske točke za sljedeći sprint. Izvještaj nastaje na temelju metrika sprinta (velocity, completion ratio, burndown) i povijesti blokera, uz pravilo da se rizik označi kad se isti tip blokera pojavi u dva ili više uzastopnih sprintova.



Slika 9. Životni ciklus IT projekta s AI integracijom (vlastita obrada autora)

5.2. Prediktivna analitika i upravljanje rizicima

Prediktivna analitika analizira podatke prethodnih projekata kako bi pronašla obrasce koji ukazuju na moguće probleme [3]. Prema Breeze PM istraživanju [7], organizacije koje koriste takve alate bilježe do 21% manje kašnjenja projekata.

Asanin alat AI Risk Prediction analizira status zadataka, povijest kašnjenja i opterećenje tima te procjenjuje koliko je vjerojatno prekoračenje roka. Na sličan način, Monday.com koristi ML za prepoznavanje ugroženih aktivnosti i predlaže preraspored resursa dok je još moguće spriječiti kašnjenje. Ovi sustavi posebno su korisni za portfelje od desetaka projekata gdje ljudski PM ne može svakodnevno pratiti svaki rizik.

6. ETIČKA I SIGURNOSNA OGRANIČENJA

6.1. Privatnost i povjerljivost podataka

Korištenje AI alata u tvrtkama otvara ozbiljna pitanja o privatnosti i sigurnosti podataka. Ako se interni dokumenti dijele s vanjskim AI servisima, postoji rizik od curjenja povjerljivih informacija [8]. Ključni rizici su:

- **Intelektualno vlasništvo:** vlastiti kod i poslovne strategije mogu biti obrađeni od strane pružatelja AI usluge.
- **Usklađenost s propisima:** GDPR i slični propisi ograničavaju gdje i kako se smiju obrađivati osobni podaci.
- **Ovisnost o jednom dobavljaču:** duboka integracija s jednim AI pružateljem otežava budući prelazak na drugu platformu.
- **Neprovjerena točnost:** AI odgovori moraju se provjeravati jer mogu sadržavati netočne podatke.

Preporuka je koristiti poslovne verzije AI alata koje jamče da se podaci ne koriste za treniranje modela (ChatGPT Enterprise, Microsoft Copilot for M365) ili privatne, lokalne LLM instalacije za projekte s osjetljivim podacima.

6.2. Problem halucinacija u planiranju projekata

Halucinacije AI modela – situacije kada AI daje uvjerljivo zvučeće, ali netočne informacije – posebno su opasne u planiranju projekata [3]. AI može napisati realističan vremenski plan koji ne odražava stvarne kapacitete tima, navesti nepostojeće preporuke ili predložiti netočne tehničke specifikacije.

Podatak da 70 – 85% GenAI implementacija ne ostvari očekivani povrat ulaganja [8] dijelom se objašnjava upravo time što timovi ne provjeravaju dovoljno AI outpute. Kao zaštita, preporučuje se obvezna ljudska provjera svih AI-generiranih planova, jasno označavanje sadržaja koji je napisao AI te korištenje RAG (Retrieval-Augmented Generation) pristupa koji AI model veže uz provjerene izvore.

7. ZAKLJUČAK

Ovaj rad pokazuje da AI u upravljanju projektima nije samo prolazni trend, već pravi alat koji donosi stvarne koristi u svakoj fazi rada. Kroz pregled tehnika upravljanja projektima – izrade WBS-a, pisanja korisničkih priča, vremenskog raspoređivanja, praćenja napretka i izvještavanja – pokazano je da AI alati mogu drastično ubrzati posao koji projektni menadžer inače radi ručno. ChatGPT, GitHub Copilot, Asana AI i Monday.com AI ubrzavaju planiranje, smanjuju birokratski posao, bolje predviđaju rizike i povećavaju produktivnost razvojnih timova.

Hoće li AI zamijeniti projektne menadžere? Podaci daju jasan odgovor: neće. AI preuzima ponavljajuće i analitičke dijelove posla, dok projektni menadžer zadržava nezamjenjivu ulogu u komunikaciji s ljudima, pregovaranju s naručiteljima, donošenju prosudbi i rješavanju nepredvidivih situacija – sve aktivnosti koje AI ne može vjerodostojno preuzeti.

Budućnost upravljanja projektima bit će suradnja čovjeka i AI-a, gdje projektni menadžer postaje koordinator AI agenata. Organizacije koje ulažu u znanje svojih timova o AI alatima i koje postave jasna pravila njihovog korištenja imat će prednost pred onima koje to ne učine. Pritom je ključno biti svjestan i ograničenja – privatnosti podataka i sklonosti AI-a halucinacijama – jer samo kombinacija AI brzine i ljudske prosudbe daje rezultate.

LITERATURA

[1] Pertama Partners, "AI Project Failure Statistics 2026," 2025. [Online]. Dostupno: https://www.pertamapartners.com/insights/ai-project-failure-statistics-2026

[2] Project.co, "The Use of AI in Project Management Statistics 2024," 2024. [Online]. Dostupno: https://project.co/ai-statistics/

[3] I. Goodfellow, Y. Bengio i A. Courville, Deep Learning. Cambridge, MA: MIT Press, 2016.

[4] H. Kerzner, Project Management: A Systems Approach to Planning, Scheduling, and Controlling, 12. izd. Hoboken, NJ: Wiley, 2017.

[5] S. Russell i P. Norvig, Artificial Intelligence: A Modern Approach, 4. izd. Hoboken, NJ: Prentice Hall, 2020.

[6] T. Freitag, "ClickUp vs Asana vs Monday.com – AI Features Comparison," 2025. [Online]. Dostupno: https://till-freitag.com/en/blog/clickup-asana-monday-ai-comparison-en

[7] Breeze PM, "AI Project Management Statistics and Trends for 2026," 2026. [Online]. Dostupno: https://www.breeze.pm/articles/ai-project-management-statistics

[8] NTT DATA Group, "Between 70–85% of GenAI deployment efforts are failing to meet their desired ROI," 2024. [Online]. Dostupno: https://www.nttdata.com/global/en/insights/focus/2024

[9] K. Schwaber i J. Sutherland, "The Scrum Guide," 2020. [Online]. Dostupno: https://scrumguides.org/scrum-guide.html

[10] M. Cohn, Agile Estimating and Planning. Upper Saddle River, NJ: Prentice Hall, 2005.

[11] D. J. Anderson, Kanban: Successful Evolutionary Change for Your Technology Business. Sequim, WA: Blue Hole Press, 2010.

SAŽETAK

Primjena umjetne inteligencije pri upravljanju projektima

U ovom radu analizirana je primjena umjetne inteligencije u upravljanju IT projektima. Obrađeni su temeljni pojmovi AI-a i upravljanja projektima, utjecaj AI-a na Trokut ograničenja te osnovne metodologije (Waterfall, Agile, Scrum). Središnji dio rada detaljno prikazuje konkretne tehnike upravljanja projektima – izradu WBS strukture, pisanje korisničkih priča, vremensko raspoređivanje kroz Gantt dijagram, praćenje napretka kroz Burndown i Velocity, status izvještavanje i Traceability Matrix – te pokazuje kako AI alati ubrzavaju svaku od njih. Predstavljeni su ključni alati (ChatGPT, GitHub Copilot, Asana, Monday.com, ClickUp) s konkretnim primjerima upotrebe i međusobnom usporedbom. Obrađena je i automatizacija rutinskih zadataka uz konkretne primjere te etički i sigurnosni izazovi – privatnost podataka i halucinacije AI modela. Zaključak je da AI ne zamjenjuje projektne menadžere, već im mijenja ulogu prema koordinatoru AI agenata.

Ključne riječi: umjetna inteligencija; upravljanje projektima; WBS; Gantt; Burndown; korisničke priče; automatizacija; ChatGPT; GitHub Copilot; Asana AI; prediktivna analitika; IT projekti